

Classificação de Abalone

Avaliação e seleção de modelos preditivos

Machine Learning

Equipe Delta

Felipe Lira

Objetivo e conjunto de dados

Estimar a capacidade de generalização de classificadores para prever o tipo de Abalone em três classes.

Dados de desenvolvimento

3.132 amostras rotuladas.
Classes 1, 2 e 3 com proporções próximas.

Variáveis explicativas

Comprimento, diâmetro, altura e quatro pesos.
Categoria sex codificada como atributo categórico.

Avaliação externa: 1.045 amostras sem alvo disponível em abalone_app.csv.

Preparação dos dados

Valores ausentes

Mediana nas variáveis numéricas.

Divisões inválidas tornam-se ausências, sem excluir linhas.

height é 0 na linha 198 e 3080 e a divisão resulta em NaN no atributo BMI.

Representação

One-hot encoding para sex. Padronização para KNN, regressão logística e SVM.

Engenharia de atributos

Quatro razões de dimensões e pesos, mantendo os atributos originais.

Imputação e escala aprendidas somente no treino de cada partição, evitando vazamento.

Delineamento experimental

Divisão estratificada

80% para desenvolvimento: 2.505 amostras.
20% para teste local: 627 amostras.

Validação cruzada

Stratified K-Fold com $k = 5$ no desenvolvimento.
Quatro partes treinam e uma valida em cada rodada.

Seleção e avaliação

Até 20 configurações por algoritmo. Seleção pela
acurácia média de CV e avaliação posterior no teste.

Mesmas partições para todos os modelos. Semente 42. F1-macro como métrica complementar.

Algoritmos e hiperparâmetros

Classificador	Princípio	Parâmetros principais
KNN	Vizinhança no espaço de atributos	k, distância e ponderação
Regressão logística	Fronteiras lineares de decisão	C e pesos de classe
Random Forest	Agregação de árvores aleatórias	Árvores, profundidade e folhas
HGB	Boosting de árvores com histogramas	Taxa de aprendizado e L2
SVM com RBF	Separação não linear com kernel	C e gamma
Extra Trees	Árvores com divisões aleatórias	Atributos, profundidade e folhas

Modelos lineares, métodos de distância e conjuntos de árvores sob o mesmo protocolo.

Resultados da validação cruzada

Classificador	Acurácia média	Desvio entre folds	F1-macro
SVM	65,83%	1,10 p.p.	65,52%
LogReg	65,71%	1,26 p.p.	65,13%
ExtraTrees	65,51%	0,54 p.p.	64,82%
KNN	65,31%	1,61 p.p.	65,15%
RandomForest	64,91%	1,82 p.p.	64,61%
HGB	63,43%	2,39 p.p.	63,12%

SVM: 65,83%. Diferença de 0,12 p.p. para LogReg, sem evidência de superioridade estatística.

Modelo selecionado: SVM com kernel RBF

A SVM busca uma margem de separação ampla, permitindo violações controladas por C.

$$K(x, z) = \exp(-\gamma \|x - z\|^2)$$

O kernel RBF permite fronteiras não lineares.
 γ controla a influência dos exemplos na fronteira.

Configuração: C = 1,0 e gamma = scale.
Atributos originais e razões, com padronização.

Desempenho no teste local

Acurácia: 67,15% F1-macro: 67,06%

Classe	Precisão	Recall	F1	Suporte
1	77,57%	76,85%	77,21%	216
2	53,46%	57,71%	55,50%	201
3	70,92%	66,19%	68,47%	210

A classe 2 apresenta o menor F1: 55,50%. Teste local com 627 observações.

Matriz de confusão da SVM

Teste local: 627 amostras. Acurácia: 67,15%.

Linhas: classe real. Colunas: classe prevista.

Real / Prevista	Classe 1	Classe 2	Classe 3
Classe 1	166	44	6
Classe 2	34	116	51
Classe 3	14	57	139

421 acertos
206 erros

108 confusões entre
as classes 2 e 3:
51 de 2 para 3
57 de 3 para 2

Contagens absolutas. O servidor informou apenas a acurácia, sem matriz externa.

Conclusões e generalização

Resultado

SVM: 66,12% de acurácia no servidor.
Resultado anterior, LogReg: 65,07%. Ganho: 1,05 p.p.

Aplicação

Treinamento final nas 3.132 amostras rotuladas.
Envio da SVM confirmado pelo servidor (success).

Os resultados estimam a generalização. Não garantem o desempenho em novos dados.

Referências

Documentação técnica

scikit-learn. Support Vector Machines.
scikit-learn.org/stable/modules/svm.html

scikit-learn. Cross-validation: evaluating estimator performance.
scikit-learn.org/stable/modules/cross_validation.html

Fontes: selection_report.json e retorno do servidor (Delta). Referências: 01/10/2026.

OBRIGADO!